



IA AVANZADA PARA LA CIENCIA DE DATOS

# Reto académico: Spaceship Titanic

*Emilio Torres Paul | A01753010*

*Ana Paula Moreno Frías | A01751886*

*David Tinoco Romero | A0141891*

*Alejandro Vázquez De La Cruz | A01800791*

*Emilio Páez De La Mora | A01801224*





IA AVANZADA PARA LA CIENCIA DE DATOS

# Sección I

Contexto inicial, identificación de problema, estrategia de ejecución, evaluación y tratamiento de los datos.



# AI Problem Definition Canvas



## AI PROBLEM DEFINITION CANVAS

Del problema de negocio a un problema evaluable de IA

Equipo 2

### 1. PROBLEMA

Actualmente el equipo de rescate espacial enfrenta la incapacidad de identificar a los pasajeros desaparecidos debido a la colisión con una anomalía cósmica que corrompió los sistemas de registro, provocando retrasos críticos en las expediciones de búsqueda y un alto riesgo de abandono de víctimas.

### 2. STAKEHOLDERS

**Principales:** Comandantes del equipo de rescate, Agencia Espacial (quien financia), familiares de las víctimas.

**Secundarios:** Aseguradoras (quienes pagan por los perdidos), Tripulación y pasajeros no desaparecidos (quienes podrían verse afectados indirectamente).

### 3. DECISIÓN

Ayudar al comandante de rescate a decidir qué lista exacta de pasajeros y áreas priorizar en la búsqueda porque actualmente los registros están mezclados y no distinguen entre pasajeros a salvo y transportados.

### 4. HIPÓTESIS DE VALOR

Creemos que si podemos clasificar con alta precisión qué pasajeros fueron transportados, entonces el equipo de rescate podrá focalizar los recursos de búsqueda en los perfiles correctos, permitiendo minimizar el tiempo de rescate y reducir el desperdicio operativo.

### 5. CAPACIDAD IA

Aprender patrones en los registros históricos de pasajeros y utilizarlos para estimar la probabilidad de que un nuevo pasajero haya sido transportado.

### 6. INPUT

- Estado del pasajero (ej. CryoSleep),
- ubicación en la nave (cabina, cubierta),
- gastos en amenidades (RoomService, Spa, VRDeck)
- características demográficas (edad, planeta de origen).

### 7. OUTPUT

El sistema entregará una tabla o lista de pasajeros etiquetados con su predicción (Transported: True/False) y un score de probabilidad. Este resultado lo consumirá el equipo de logística de rescate.

### 8. TIPO DE PROBLEMA

Aprendizaje supervisado para clasificación binaria, porque existen dos posibles clases: transportado / no transportado.

### 9. BASELINE

Nuestra solución debe ser mejor que una heurística simple humana o un modelo base que prediga siempre la clase mayoritaria.

### 10. ERROR CRÍTICO

- Falso negativo - Si el modelo marca a alguien como no transportado cuando en realidad lo fue, provoca que se abandone una búsqueda que se debió haber llevado a cabo.
- Falso positivo (menor medida) - El modelo marca a alguien como transportado cuando no lo fue y se invierte tiempo y recurso en una búsqueda innecesaria.

### 11. ÉXITO TÉCNICO

Consideraremos técnicamente prometedor la solución si maximizamos el Recall de la clase 'Transported=True' (para mitigar los falsos negativos) logrando al menos un 80%, manteniendo un F1-Score que supere al baseline heurístico, demostrando que no solo disparamos falsas alarmas.

### 12. ÉXITO NEGOCIO

Reducción en un 50% del tiempo invertido en la elaboración de listas de búsqueda comparado con el proceso manual. Además de una reducción en desperdicio de recursos provocada por malos registros.



### ⚠ SUPUESTOS, RESTRICCIONES E INCERTIDUMBRES

**Supuestos:** El patrón de "transporte a otra dimensión" dejó rastros identificables en el gasto y ubicación dentro de la nave antes del choque. Las etiquetas del registro de entrenamiento son 100% verificadas.

**Restricciones:** Existen valores nulos críticos en columnas de ubicación y gastos financieros que requerirán imputación y escalado; solo se cuenta con información pre-anomalia.



**Incertidumbres:** ¿El rescate requiere saber a qué dimensión fueron transportados, o solo el hecho de que desaparecieron? ¿Qué umbral de probabilidad de transporte justifica el costo de enviar una unidad de búsqueda?

# Análisis Exploratorio de Datos (EDA).




- **Clases balanceadas:** 50.4% transportados / 49.6% no transportados. Al no haber una clase dominante, el accuracy es una métrica confiable para evaluar el modelo.
- **CryoSleep** es el feature clave: los pasajeros dormidos (en animación suspendida) tienen una tasa de transporte mucho más alta que los despiertos.
- **Descubrimiento útil:** estos mismos pasajeros dormidos no gastaron nada a bordo, esto nos permitió tratar datos faltantes con lógica, en vez de solo con promedios.

# Análisis Exploratorio de Datos (EDA).



- **La ubicación en el barco es importante:** los decks B y C tienen ~68-73% de probabilidad de transporte, mientras que E y F caen a ~36-44%, casi el doble de diferencia entre secciones, muy por encima del promedio general (50.4%)
  - Se aprecia que A, B, y C se encuentran cercanos o por encima del promedio general (excluyendo a G), lo que puede indicar ordinalidad en deck.
  - Viajar en estribor (Side = S) da más probabilidad de ser transportado, que estar en babor (Side = P)
- **Viajar acompañado también inflúa:** el tamaño del grupo de viaje se relaciona con la probabilidad de ser transportado.
- **Descubrimiento útil:** el tamaño del grupo de viaje se relaciona con la probabilidad de ser transportado, así que lo convertimos en una variable nueva, llamada "group\_size".

# Apéndice — Deck como variable ordinal



- Anotación del profesor: en vez de One-Hot Encoding (sin orden), probamos Deck como variable ordinal.
- Orden elegido: empírico, por tasa real de Transported (T→E→D→F→A→G→C→B), no alfabético — el alfabeto no tiene relación con el resultado.
- La gráfica muestra por qué tiene sentido ordenar así: la tasa sube de forma casi monótona de T (20%) a B (73%), un rango de +53 puntos porcentuales entre la cubierta más baja y la más alta.
- Resultado: F1 = 0.8014 (ordinal) vs. 0.8000 (One-Hot) — mejora marginal, pero con 6 columnas menos (21 vs. 27).
- **No reemplaza el pipeline principal:** el orden usa la tasa de Transported de train, es decir, información del target — válido como exploración (target encoding), pero se documenta aparte para no meter ese riesgo al modelo final.

```
Shape con Deck ordinal: (8693, 21)
{ Shape con Deck ordinal: (8693, 21)
  { F1 (RF base, Deck ordinal): 0.8014
    F1 (RF base, Deck one-hot): 0.8000
```

In

ey

# Limpieza y transformación de datos



| Variable               | Acción                                             | Razón                                     |
|------------------------|----------------------------------------------------|-------------------------------------------|
| CryoSleep              | Imputación lógica + moda + binario                 | Correlación con gasto total               |
| Gastos                 | Imputación lógica + mediana + log1p + RobustScaler | Sesgo alto + outliers                     |
| Age                    | Mediana + RobustScaler                             | Distribución simétrica                    |
| Cabin                  | Separada en Deck, CabinNum, Side                   | Cardinalidad inmanejable                  |
| CabinNum               | Mediana + agrupado en bins de 300                  | Captura de secciones física               |
| HomePlanet/Destination | Moda + One-Hot Encoding                            | Categórica sin jerarquía                  |
| PassengerId            | Extraído a group_size                              | Viajar en grupo afecta el target          |
| VIP/Name               | Descartadas                                        | Sin valor predictivo / desbalance extremo |



IA AVANZADA PARA LA CIENCIA DE DATOS

# Sección II

Desarrollo inicial de modelos



# Primeros modelos y decisión inicial



- Probamos **dos modelos** de familias distintas: Regresión Logística (lineal) y Random Forest (ensamble de árboles).
- Regresión Logística: 79.4% accuracy, mejor recall (192 falsos positivos, 167 falsos negativos).
- Random Forest: 79.9% accuracy, mejor precision y F1, pero peor recall (174 falsos positivos, 176 falsos negativos): se volvió más "conservador" al predecir "transportado".
- La diferencia fue pequeña, sin embargo, elegimos Random Forest no porque ganara en todo, sino porque fue el único con mejora en F1 (aunque mínima) y porque tiene más espacio de mejora ajustando hiperparámetros.

|   | Modelo              | Accuracy | Precision | Recall   | F1-score |
|---|---------------------|----------|-----------|----------|----------|
| 0 | Baseline            | 0.503624 | NaN       | NaN      | NaN      |
| 1 | Regresión Logística | 0.793560 | 0.786903  | 0.809361 | 0.797974 |
| 2 | Random Forest       | 0.798735 | 0.800915  | 0.799087 | 0.800000 |



# Diagnóstico del modelo antes de ajustarlo



Medimos el comportamiento de Random Forest del avance 2 con curvas de aprendizaje y curvas de validación.

- **1er hallazgo:** Con pocos datos, el modelo memorizaba casi perfecto aquello que ya conocía, al darle datos nuevos, presentó una mejora, sin embargo, no llegó a ser tan bueno como con los datos conocidos.
- **2do hallazgo:** El punto óptimo resultó ser la configuración que estábamos usando, ya que era una balance entre muy simple y muy complejo.

Con esto pudimos confirmar que antes de refinar el modelo, íbamos en el camino correcto.



# Tuneado de hiperparámetros



## 0.1 Cómo buscamos

### RandomizedSearchCV

El espacio tenía 2,100 combinaciones; probarlas todas habría sido 10,500 entrenamientos. Probamos 20 al azar, en el rango que ya nos habían señalado las curvas. Validación cruzada K=5, criterio F1.

## 0.2 Qué encontró

### Mejor configuración

n\_estimators = 300  
max\_depth = 12  
min\_samples\_leaf = 5  
min\_samples\_split = 5  
max\_features = 'sqrt'

## 0.3 Qué cambió

### Más profundo, pero más exigente

No es un árbol más profundo a secas: subió de 10 a 12, pero exigiendo 5 muestras mínimo por hoja en vez de 1. Le dio capacidad por un lado y se la frenó por otro. Y más árboles votando: 300 en vez de 200.

## 0.4 Qué tanto sirvió

### Medido en el conjunto de prueba

F1  
0.800  
→0.805

ROC-AUC  
0.897 →  
0.898

El F1 subió poco y el ROC-AUC casi nada. Esa segunda métrica nos dice que el tuning no mejoró la separación entre clases: solo reajustó el punto de corte.



IA AVANZADA PARA LA CIENCIA DE DATOS

# Sección III


Análisis de resultados, conclusiones, siguientes pasos.




# Resultado final del modelo (Random Forest)




- Comparamos 3 versiones para aislar el efecto de cada paso: Random Forest sin ajustar, el configurado a mano en el avance anterior, y la versión final tras el tuning sistemático.
- Las tres superan el 50%, la ganancia grande vino de elegir bien el modelo base.
- El tuning automático (RandomizedSearchCV) mejoró el modelo, pero poco, confirma lo que ya veíamos en el diagnóstico: la configuración inicial ya estaba cerca de su punto óptimo.
- Esto nos dice que seguir ajustando este modelo ya no es donde está la oportunidad, mejorar más requeriría mejores variables o un modelo distinto (siguiente slide).



El modelo acertó en 1,396 de 1,739 casos. Los errores (175 y 168) están casi parejos entre los dos tipos, no se equivoca más hacia un lado que hacia otro.



Las tres versiones del modelo tienen desempeño similar. La versión final (verde) es la más consistente, con su mayor mejora en Recall.



Comparación de Accuracy, Precision, Recall y F1-score entre el modelo sin ajustar, el del avance 2 y el modelo final tuneado.

# Selección del modelo adecuado



- Regresión Logística: por debajo del RF en las métricas compuestas
- SVC: el único modelo individual que superó al Random Forest del equipo en las cinco métricas.
- KNN: por debajo del RF, debido a las ~26 dimensiones
- Naive Bayes: el supuesto de independencia condicional entre variables es poco realista aquí (CryoSleep)
- Red Neuronal / MLP: por debajo del RF; con un dataset de tamaño moderado (~7,000 filas de entrenamiento)

| Integrante             | Modelo              | F1-score | ROC-AUC | ¿Superó al RF del equipo? | ¿Cambiaría la decisión? |
|------------------------|---------------------|----------|---------|---------------------------|-------------------------|
| Ana Paula Moreno       | Regresión Logística | 0.7934   | 0.8677  | No                        | No                      |
| David Tinoco Romero    | SVC                 | 0.8106   | 0.8945  | Sí                        | Sí                      |
| Emilio Páez de la Mora | KNN                 | 0.7603   | 0.8747  | No                        | No                      |
| Emilio Torres Paul     | Naive Bayes         | 0.7068   | 0.7876  | No                        | No                      |
| Alejandro Vázquez      | Red Neuronal (MLP)  | 0.7917   | 0.8881  | No                        | No                      |

Al ser el único modelo individual que superó al Random Forest del equipo en las cinco métricas, se reconstruyó el SVC con sus hiperparámetros óptimos (kernel rbf, C=150, gamma=0.005) y se comparó con el Random Forest tuneado sobre el mismo conjunto de prueba



IA AVANZADA PARA LA CIENCIA DE DATOS

# Sección IV

Modelo final. SVC



# ¿Por qué SVC?




## Funcionamiento de un SVC

- **Búsqueda del hiperplano óptimo:** El algoritmo busca dibujar una frontera de decisión (un "hiperplano") en el espacio de características que separe los datos en clases distintas.
- **Maximización del margen:** A diferencia de otros modelos, el SVC no se conforma con cualquier frontera que separe los datos, sino que busca matemáticamente la que maximice el espacio vacío (margen) entre las clases.
- **El "Truco del Kernel" (Kernel Trick):** Cuando los datos están mezclados de una forma que no se puede dividir con una línea o plano recto, el SVC utiliza funciones (kernels), como el Radial Basis Function o **rbf** para proyectar los datos a un espacio de múltiples dimensiones.

## Por qué para Spaceship Titanic

- **Naturaleza exacta del problema:** La arquitectura base del SVC fue creada específicamente y está optimizada al máximo para separar problemas de exactamente dos clases.
- **Complejidad no lineal de los atributos:** Los datos de entrada combinan múltiples rangos y su probabilidad de ser transportado por la anomalía no obedece a una simple regla lineal. La capacidad del SVC (con su kernel **rbf**) para detectar fronteras irregulares y relaciones curvas lo convertía en una herramienta ideal para estos datos.



# Como llegamos al modelo final



## 0.1 Planteamiento del modelo

Implementamos un pipeline con estandarización previa de los datos. Diseñamos una estrategia de optimización en dos fases para maximizar la eficiencia y precisión: primero utilizamos un RandomizedSearchCV y posteriormente aplicamos un GridSearchCV

## 0.2 Randomized Search CV

Evaluamos 20 candidatos aleatorios y detectamos patrones muy claros que sirvieron para construir nuestra grilla final.

El kernel polinomial de grado 2 lideraba, con una regularización baja ( $C=1$ ) y un gamma de 0.1, mientras que el kernel radial (rbf) se consolidó después, dando valores más estrictos ( $C=100$ ) y un gamma de 0.01.


## 0.3 Grid Search CV

El kernel no lineal rbf superó al polinomial y elevó el F1-score promedio en validación cruzada a 0.8077. La combinación ganadora de  $C=150$  y  $\text{gamma}=0.005$  indica que el modelo requirió un hiperplano bastante estricto con los errores de clasificación, el cual tiene un radio de influencia muy suave (ayuda a evitar overfitting).

# ¿Qué tal le fue a SVC?



- **Mitigación del Error Crítico (Vidas en juego):** El impacto más grave para la operación es el falso negativo, es decir, clasificar a un pasajero como "no transportado" cuando en realidad sí lo fue, lo que provoca el abandono prematuro de su búsqueda. La arquitectura del SVC demostró ser la más efectiva para reducir esta fuga, protegiendo vidas reales.
- **Cumplimiento del Éxito Técnico:** El estándar del proyecto exige maximizar el *Recall* de la clase "Transported=True" por encima del 80% y mantener un F1-Score superior al modelo base. El SVC supera ambos umbrales matemáticos (Recall de 0.8185 y F1-score de 0.8106), validando su viabilidad técnica
- **Optimización de la Decisión Operativa:** El modelo entrega una lista con probabilidades de alta sensibilidad que ayuda directamente al comandante de rescate a decidir qué áreas priorizar. Esto confirma la hipótesis de valor del negocio: focalizar los recursos de búsqueda, minimizar el tiempo de rescate y reducir drásticamente el desperdicio operativo.



|           | Modelo del equipo (RF tuneado) | SVC (David) | Diferencia (SVC - RF) | Diferencia (pp) |
|-----------|--------------------------------|-------------|-----------------------|-----------------|
| F1-score  | 0.8050                         | 0.8106      | 0.0056                | 0.5625          |
| ROC-AUC   | 0.8984                         | 0.8945      | -0.0039               | -0.3942         |
| Accuracy  | 0.8028                         | 0.8074      | 0.0046                | 0.4600          |
| Precision | 0.8018                         | 0.8029      | 0.0011                | 0.1100          |
| Recall    | 0.8082                         | 0.8185      | 0.0103                | 1.0274          |

# Solución - Interfaz para utilizar el modelo



- Construimos una app web (Flask) que expone los dos modelos de la estrategia dual (Random Forest y SVC) listos para predecir, sin reentrenar nada.
- Predicción individual: formulario con los datos de un pasajero → predicción (Transported: sí/no) + probabilidad, con un selector para elegir qué modelo usar.
- Predicción por lote: sube un .csv/.xlsx con varios pasajeros → tabla de resultados + resumen (total, transportados, probabilidad promedio) + descarga en .csv.
- El mismo objeto SpaceshipPreprocessor (Sección 2) se reutiliza aquí — el pasajero que llega por la interfaz se procesa exactamente igual que en entrenamiento, sin duplicar lógica.

Spaceship Titanic — Predicción individual

Modelo: SVC (recomendado) | HomePlanet: Earth

CryoSleep: False | Destination: TRAPPIST-1e

Age: 30 | Deck: F

CabinNum: 100 | Side: P

RoomService: 0 | FoodCourt: 0

ShoppingMall: 0 | Spa: 0

VRDeck: 0

Predecir

Link: <http://127.0.0.1:5000>

correr `pip install flask pandas scikit-learn joblib openpyxl`

Después correr app.py

Archivo (csv o .xlsx) Choose File pasajeros\_prueba.xlsx

Predicción lote

Total pasajeros: 15 | Transportados: 9 / 15 | Probabilidad promedio: 58.3%

| PassengerId | Transported | Probabilidad |
|-------------|-------------|--------------|
| 0001_01     | Si          | 58.4%        |
| 0002_01     | No          | 16.9%        |
| 0003_01     | Si          | 97.2%        |
| 0003_02     | Si          | 97.3%        |
| 0003_03     | Si          | 96.5%        |
| 0004_01     | No          | 10.6%        |
| 0005_01     | Si          | 87.9%        |
| 0006_01     | No          | 20.3%        |
| 0007_01     | No          | 27.8%        |
| 0008_01     | No          | 10.7%        |
| 0009_01     | Si          | 68.3%        |
| 0009_02     | Si          | 81.8%        |

Descargar resultados (CSV)



# La iteración continua es fundamental para la evolución de los proyectos de Machine Learning.



- + [01] **Resumen de Hallazgos:** Síntesis del rendimiento final alcanzado y cómo éste resuelve el problema planteado inicialmente.
- + [02] **Limitaciones del Proyecto:** Reconocimiento transparente de los sesgos en los datos, restricciones de cómputo o debilidades del algoritmo.
- + [03] **Siguientes Pasos:** Propuestas para recolectar un volumen mayor de datos de mejor calidad.
- + [04] **Trabajo Futuro:** Exploración de arquitecturas más complejas (Gradient Boosting, Deep Learning) o mejora en las técnicas de explicabilidad del modelo (XAI).